



0c0760_a300ee12f6054...
PDF

내용 파악



KKT 조건이란?

KKT 조건(Karush–Kuhn–Tucker conditions)은 제약조건이 있는 최적화 문제에서 해가 최적해가 되기 위해 만족해야 하는 조건입니다.

일반적인 라그랑주 승수법은 등식 제약조건만 다룹니다.

$$h(x) = 0$$

KKT 조건은 여기에 부등식 제약조건까지 포함합니다.

$$g(x) \leq 0 \quad \text{또는} \quad g(x) \geq 0$$

즉, KKT 조건은 다음과 같은 문제를 다룰 때 사용됩니다.

$$\begin{aligned} \min_x f(x) \\ \text{s.t. } h(x) = 0, \quad g(x) \leq 0 \end{aligned}$$

논문에서는 NeuralSDF-triangle 충돌 검출을 삼각형 내부에서 SDF 값을 최소화하는 **constrained optimization** 문제로 만들고, 그 최적해가 만족해야 하는 KKT 조건을 유도합니다.

0c0760_a300ee12f6054b399ed0e4b4...

1. 이 논문의 최적화 문제

삼각형의 세 꼭짓점을

$$v_1, v_2, v_3$$

라고 할 때, 삼각형 내부의 점 p 는 barycentric coordinate로 표현됩니다.

$$p = \alpha v_1 + \beta v_2 + \gamma v_3$$

이 점이 삼각형 안에 있으려면 다음 조건을 만족해야 합니다.

$$\alpha + \beta + \gamma = 1$$

$$\alpha, \beta, \gamma \geq 0$$

논문에서 풀고 싶은 문제는 다음입니다.

$$\min_{\alpha, \beta, \gamma} f_{SDF}(\alpha v_1 + \beta v_2 + \gamma v_3)$$

s.t. $\alpha + \beta + \gamma = 1, \quad \alpha, \beta, \gamma \geq 0$

즉,

삼각형 위의 모든 점 중에서 NeuralSDF 값이 가장 작은 점을 찾는다.

이 점이 NeuralSDF 물체와 mesh 삼각형 사이의 contact point 후보가 됩니다.

0c0760_a300ee12f6054b399ed0e4b4...

2. KKT 조건의 네 가지 구성

KKT 조건은 보통 네 가지로 구성됩니다.

조건	의미
Stationarity	최적점에서 목적함수와 제약조건의 gradient가 균형을 이룸
Primal feasibility	원래 제약조건을 만족해야 함
Dual feasibility	부등식 제약의 multiplier가 음수가 아니어야 함
Complementary slackness	제약조건이 실제로 활성화된 경우와 multiplier의 관계를 나타냄

이 네 가지를 하나씩 이 논문의 문제에 적용하면 됩니다.

3. Lagrangian 구성

논문은 다음 Lagrangian을 정의합니다.

$$\mathcal{L}(\alpha, \beta, \gamma, \lambda, \mu_1, \mu_2, \mu_3) = f_{SDF}(p) + \lambda(\alpha + \beta + \gamma - 1) - \mu_1\alpha - \mu_2\beta - \mu_3\gamma$$

여기서

$$p = \alpha v_1 + \beta v_2 + \gamma v_3$$

입니다.

각 multiplier의 의미는 다음과 같습니다.

기호	의미
λ	등식 제약 $\alpha + \beta + \gamma = 1$ 에 대한 라그랑주 승수

기호	의미
μ_1	부등식 제약 $\alpha \geq 0$ 에 대한 승수
μ_2	부등식 제약 $\beta \geq 0$ 에 대한 승수
μ_3	부등식 제약 $\gamma \geq 0$ 에 대한 승수

4. Stationarity 조건

최적점에서는 Lagrangian을 α, β, γ 에 대해 미분했을 때 0이어야 합니다.

$$\frac{\partial \mathcal{L}}{\partial \alpha} = 0$$

$$\frac{\partial \mathcal{L}}{\partial \beta} = 0$$

$$\frac{\partial \mathcal{L}}{\partial \gamma} = 0$$

이를 정리하면 논문에서는 다음과 같이 씁니다.

$$v_i^T \nabla f_{SDF}(p) + \lambda - \mu_i = 0, \quad i \in \{1, 2, 3\}$$

여기서

$$\nabla f_{SDF}(p)$$

는 점 p 에서의 SDF gradient입니다.

직관적으로는 다음 뜻입니다.

최적점에서는 SDF를 줄이려는 방향과, 삼각형 내부에 머물러야 한다는 제약조건이 균형을 이룬다.

5. Primal feasibility 조건

예측된 점 p 는 반드시 삼각형 내부에 있어야 합니다.

따라서 barycentric coordinate는 다음을 만족해야 합니다.

$$\alpha + \beta + \gamma = 1$$

$$\alpha, \beta, \gamma \geq 0$$

이 조건이 바로 **primal feasibility**입니다.

이 논문에서는 네트워크 출력에 softmax를 사용하기 때문에

$$\alpha + \beta + \gamma = 1$$

$$\alpha, \beta, \gamma \geq 0$$

가 구조적으로 자동 만족됩니다. 즉, 네트워크가 항상 삼각형 내부의 점만 출력하도록 설계되어 있습니다.  0c0760_a300ee12f6054b399ed0e4b4...

6. Dual feasibility 조건

부등식 제약조건의 multiplier는 음수가 아니어야 합니다.

$$\mu_1, \mu_2, \mu_3 \geq 0$$

이 조건은 제약조건이 최적화 문제에서 “얼마나 강하게 작용하는지”를 나타냅니다.

예를 들어 $\alpha = 0$ 이면 점 p 가 삼각형의 한 변 위에 있다는 뜻입니다. 이 경우 $\alpha \geq 0$ 제약이 실제로 활성화될 수 있고, μ_1 이 양수가 될 수 있습니다.

7. Complementary slackness 조건

Complementary slackness는 다음과 같습니다.

$$\alpha \mu_1 = 0$$

$$\beta \mu_2 = 0$$

$$\gamma \mu_3 = 0$$

논문에서는 이를 다음처럼 표현합니다.

$$0 \leq \alpha \perp \mu_1 \geq 0$$

$$0 \leq \beta \perp \mu_2 \geq 0$$

$$0 \leq \gamma \perp \mu_3 \geq 0$$

여기서 $\perp$ 는 두 값의 곱이 0이라는 뜻입니다.

즉,

$$\alpha\mu_1 = 0$$

이라는 의미입니다.

직관은 다음과 같습니다.

경우 1: $\alpha > 0$

점 p 가 v_1 방향 성분을 실제로 가지고 있습니다. 이때 $\alpha \geq 0$ 제약은 활성화되어 있지 않습니다.

따라서

$$\mu_1 = 0$$

이어야 합니다.

경우 2: $\alpha = 0$

점 p 가 v_1 반대쪽 edge 위에 있습니다. 이때 $\alpha \geq 0$ 제약이 활성화될 수 있습니다.

따라서

$$\mu_1 \geq 0$$

일 수 있습니다.

즉, complementary slackness는 다음을 말합니다.

어떤 부등식 제약이 실제로 경계에서 작동하지 않으면 multiplier는 0이고, 경계에 걸려 있을 때만 multiplier가 영향을 줄 수 있다.

8. 논문에서 얻는 최종 KKT optimality condition

논문은 위 KKT 조건들을 정리해서 다음 조건을 얻습니다.

$$(\nabla f_{SDF}(p))^T(p - v_{min}) = 0$$

여기서

$$v_{min} = \arg \min_{v \in \{v_1, v_2, v_3\}} \nabla f_{SDF}(p)^T v$$

입니다.  0c0760_a300ee12f6054b399ed0e4b4...

이 식이 논문에서 가장 중요한 KKT 조건입니다.

9. 이 조건의 직관

$$\nabla f_{SDF}(p)$$

는 SDF 값이 증가하는 방향입니다. SDF 표면 근처에서는 보통 물체 표면의 normal 방향과 관련됩니다.

삼각형 위에서 아직 SDF 값을 더 줄일 수 있는 방향이 있다면, p 는 최적점이 아닙니다.

반대로 최적점이라면,

삼각형 안에서 어느 방향으로 조금 움직여도 SDF 값을 더 줄일 수 없어야 합니다.

논문의 조건

$$(\nabla f_{SDF}(p))^T (p - v_{min}) = 0$$

은 바로 이것을 검사합니다.

즉,

p 에서 SDF gradient 기준으로 가장 유리한 꼭짓점 방향을 보더라도,
더 이상 SDF 값을 줄일 수 없는 상태

를 의미합니다.

10. 삼각형 내부, edge, vertex에서의 해석

KKT 조건은 contact point가 삼각형의 어디에 있는지에 따라 다르게 해석됩니다.

1. p 가 삼각형 내부에 있는 경우

$$\alpha > 0, \quad \beta > 0, \quad \gamma > 0$$

이 경우 모든 부등식 제약은 비활성입니다.

$$\mu_1 = \mu_2 = \mu_3 = 0$$

따라서 최적점에서는 SDF gradient가 삼각형 평면 안의 이동 방향들과 수직에 가까운 관계를 가집니다.

직관적으로는,

삼각형 내부에서 어느 방향으로 움직여도 SDF가 더 작아지지 않는 점

입니다.

2. p 가 edge 위에 있는 경우

예를 들어

$$\alpha = 0, \quad \beta > 0, \quad \gamma > 0$$

이면 p 는 v_2, v_3 를 잇는 edge 위에 있습니다.

이 경우 $\alpha \geq 0$ 제약이 활성화됩니다.

즉, SDF를 더 줄이는 방향이 있더라도 그 방향이 삼각형 밖으로 나가는 방향이라면 허용되지 않습니다.

3. p 가 vertex 위에 있는 경우

예를 들어

$$\alpha = 1, \quad \beta = 0, \quad \gamma = 0$$

이면 $p = v_1$ 입니다.

이 경우 두 개의 부등식 제약이 활성화됩니다.

즉, 최적점이 삼각형의 꼭짓점에 걸려 있는 상황입니다.

11. 왜 이 조건을 loss로 쓸 수 있는가?

논문은 최종 KKT 조건을 그대로 학습 loss로 사용합니다.

$$L_{op} = (\nabla f_{SDF}(p))^T (p - v_{min})$$

이 loss는 네트워크가 예측한 점 p 가 KKT optimality condition을 만족하도록 만듭니다.

즉, 네트워크는 정답 contact point label을 직접 받지 않아도 됩니다.

대신 다음을 학습합니다.

“내가 예측한 점이 constrained optimization의 최적해 조건을 만족하는가?”

이 때문에 논문에서는 이 방식을 **unsupervised learning**으로 사용할 수 있습니다.

0c0760_a300ee12f6054b399ed0e4b4...

12. KKT 조건과 amortized neural network의 관계

기존 방식은 각 삼각형마다 다음 최적화 문제를 반복적으로 풉니다.

$$p^* = \arg \min_{p \in \Delta} f_{SDF}(p)$$

예를 들어 Frank-Wolfe 같은 알고리즘을 여러 iteration 수행합니다.

하지만 논문에서는 네트워크가 바로 barycentric coordinate를 예측합니다.

$$[\alpha, \beta, \gamma] = \text{Network}(v_1, v_2, v_3, z_1, z_2, z_3, z_\Delta)$$

그다음

$$p = \alpha v_1 + \beta v_2 + \gamma v_3$$

로 contact point를 얻습니다.

이때 KKT loss가 네트워크에게 다음을 가르칩니다.

$$p \approx p^*$$

즉,

반복 최적화로 찾아야 할 최적 contact point를
신경망 forward pass 한 번으로 예측하게 만드는 것

이 이 논문의 amortized optimization 구조입니다.

핵심 요약

KKT 조건은 제약조건이 있는 최적화 문제에서 최적해가 만족해야 하는 조건입니다.

이 논문에서는 NeuralSDF-triangle 충돌 검출을 다음 문제로 정의합니다.

$$\begin{aligned} \min_{\alpha, \beta, \gamma} f_{SDF}(\alpha v_1 + \beta v_2 + \gamma v_3) \\ \text{s.t. } \alpha + \beta + \gamma = 1, \quad \alpha, \beta, \gamma \geq 0 \end{aligned}$$

그리고 KKT 조건을 통해 최적 contact point p 가 만족해야 할 조건을 다음처럼 얻습니다.

$$(\nabla f_{SDF}(p))^T (p - v_{min}) = 0$$

이 조건은 “삼각형 내부에서 더 이상 SDF 값을 줄일 수 없는 점”이라는 의미입니다.

논문은 이 식을 loss로 사용해 네트워크를 학습합니다.

$$L_{op} = (\nabla f_{SDF}(p))^T (p - v_{min})$$

결과적으로 KKT 조건은 이 논문에서 단순한 수학적 분석이 아니라, **정답 contact point 없이도 amortized neural network를 학습시키는 핵심 supervision signal** 역할을 합니다.

Thought for 1m 1s

KKT 조건의 뜻

KKT 조건은 쉽게 말하면,

제약조건이 있는 문제에서 “이 점이 최적해인지” 확인하는 조건

입니다.

이 논문에서는 충돌점을 찾는 문제가 그냥 “아무 점이나 찾기”가 아니라,

삼각형 안에 있는 점 중에서 NeuralSDF 값이 가장 작은 점을 찾는 문제

입니다. 즉,

$$p = \alpha v_1 + \beta v_2 + \gamma v_3$$

이 점이 반드시 삼각형 내부에 있어야 하므로,

$$\alpha + \beta + \gamma = 1, \quad \alpha, \beta, \gamma \geq 0$$

라는 제약조건이 붙습니다. 논문은 이 제약 최적화 문제에 대해 KKT 조건을 유도합니다.

0c0760_a300ee12f6054b399ed0e4b4...

직관적으로 무슨 뜻인가?

삼각형 위에서 NeuralSDF 값을 줄이고 싶다고 생각하면 됩니다.

- SDF 값이 작을수록 물체 표면에 더 가깝거나 내부로 더 들어간 점입니다.
- 따라서 충돌 검출에서는 삼각형 위에서 SDF 값이 가장 작은 점을 찾습니다.
- 그런데 그 점은 반드시 삼각형 밖으로 나가면 안 됩니다.

그래서 KKT 조건은 이렇게 말합니다.

삼각형 안에서 더 이상 SDF 값을 줄일 수 있는 방향이 없으면, 그 점이 최적 접촉점이다.

논문에서 나온 식의 뜻

논문에서 최종 KKT optimality condition은 다음과입니다.

$$(\nabla f_{SDF}(p))^T(p - v_{min}) = 0$$

여기서 각 기호의 뜻은 다음과 같습니다.

기호	뜻
p	네트워크가 예측한 접촉점
$f_{SDF}(p)$	그 점의 signed distance 값
$\nabla f_{SDF}(p)$	SDF 값이 증가하는 방향, 즉 표면 normal 방향
v_{min}	SDF를 줄이는 방향으로 가장 유리한 삼각형 꼭짓점
$(\cdot)^T(\cdot)$	두 방향이 얼마나 같은 방향인지 보는 내적

이 식의 의미는 다음과입니다.

점 p 에서 삼각형 안의 가장 유리한 방향으로 움직여도 SDF 값을 더 줄일 수 없다.

즉, p 가 삼각형 안에서 SDF 최소점이라는 뜻입니다.

더 쉽게 비유하면

산 위에서 가장 낮은 지점을 찾는다고 생각하면 됩니다.

- f_{SDF} : 높이
- 삼각형: 움직일 수 있는 제한된 영역
- p : 현재 위치
- $\nabla f_{SDF}(p)$: 높이가 올라가는 방향
- $-\nabla f_{SDF}(p)$: 높이가 내려가는 방향

KKT 조건은 이렇게 말합니다.

“내가 움직일 수 있는 삼각형 영역 안에서는 더 내려갈 길이 없다.”

그러면 그 점이 삼각형 안에서의 최저점입니다.

이 논문에서 왜 중요한가?

원래는 이 최저점을 찾으려면 Frank-Wolfe 같은 반복 최적화를 해야 합니다.

반복 계산 → 접촉점 찾기

하지만 논문은 KKT 조건을 loss로 사용합니다.

$$L_{op} = (\nabla f_{SDF}(p))^T (p - v_{min})$$

즉, 신경망에게 이렇게 학습시킵니다.

“네가 예측한 접촉점 p 가 KKT 조건을 만족하도록 만들어라.”

그래서 정답 접촉점 라벨이 없어도, 네트워크가 최적 접촉점을 예측하도록 학습할 수 있습니다.

0c0760_a300ee12f6054b399ed0e4b4...

한 문장 요약

KKT 조건의 뜻은 “제약조건 안에서 더 이상 좋아질 수 없는 점이 최적해다”라는 것이고, 이 논문에서는 “삼각형 안에서 SDF 값을 더 줄일 수 없는 점이 contact point다”라는 의미로 사용됩니다.

아주 좋은 질문입니다.

Posterior는 “최적화의 정답”이라기보다, 관측 후 우리가 알고 싶은 “조건부 확률분포”입니다.

즉,

$$p(z|x)$$

는

데이터 x 를 관측했을 때, 숨은 변수 z 가 어떤 값일 가능성이 있는지 나타내는 분포

입니다.

1. Posterior의 원래 의미

Bayesian inference에서 보통 다음이 있습니다.

$$p(z)$$

는 **prior**입니다.

아직 데이터를 보기 전 z 에 대한 믿음입니다.

$$p(x|z)$$

는 **likelihood**입니다.

z 가 주어졌을 때 데이터 x 가 나올 가능성입니다.

$$p(z|x)$$

는 **posterior**입니다.

데이터 x 를 본 뒤 z 에 대해 업데이트된 믿음입니다.

Bayes rule로 쓰면:

$$p(z|x) = \frac{p(x|z)p(z)}{p(x)}$$

그러니까 posterior는 하나의 숫자나 하나의 점이 아니라, 보통 **분포 전체**입니다.

2. 그럼 최적화와 무슨 관계가 있나?

Posterior 자체는 “최적화의 답”이라기보다 우리가 구하고 싶은 목표 분포입니다.

그런데 실제로는 posterior를 정확히 계산하기 어려운 경우가 많습니다.

그래서 variational inference에서는 posterior를 직접 구하지 않고, 어떤 쉬운 분포 $q(z)$ 로 근사합니다.

$$q(z) \approx p(z|x)$$

이때 최적화를 합니다.

$$q^* = \arg \min_q KL(q(z)||p(z|x))$$

또는 VAE에서는 ELBO를 최대화합니다.

$$\max_{\phi} \text{ELBO}$$

그래서 정확히 말하면:

posterior $p(z|x)$ 는 최적화의 “정답 분포”에 가깝고,
최적화의 실제 결과는 그 posterior를 근사하는 $q^*(z)$ 또는 $q_{\phi}(z|x)$ 입니다.

3. VAE에서 posterior는 어떻게 쓰이나?

VAE에서는 encoder network가 다음을 출력합니다.

$$q_{\phi}(z|x)$$

이것은 진짜 posterior가 아니라 **approximate posterior**, 즉 posterior 근사분포입니다.

예를 들어 VAE encoder가 다음을 출력한다고 하면:

$$\mu_{\phi}(x), \sigma_{\phi}(x)$$

이것은 보통 이런 분포를 의미합니다.

$$q_{\phi}(z|x) = \mathcal{N}(z; \mu_{\phi}(x), \sigma_{\phi}(x)^2)$$

즉, encoder가 z 하나를 딱 맞히는 것이 아니라,

“이 x 를 설명하는 latent variable z 는 대략 이런 평균과 분산을 가진 분포일 것이다”

라고 예측하는 것입니다.

4. Posterior와 MAP는 구분해야 함

헷갈리기 쉬운 개념이 있습니다.

Posterior는 분포입니다.

$$p(z|x)$$

반면, 그 posterior에서 가장 가능성이 높은 하나의 값은 **MAP estimate**입니다.

$$z_{MAP} = \arg \max_z p(z|x)$$

즉,

개념	의미
posterior ($p(z x)$)	
MAP z_{MAP}	posterior가 가장 큰 하나의 점
variational posterior ($q_\phi(z x)$)	
amortized inference	매번 posterior 근사를 최적화하지 않고 encoder가 바로 예측하는 방식

그래서 “posterior가 최적화의 정답이냐?”라고 물으면 답은:

분포를 구하는 관점에서는 **posterior**가 목표이고,
점 하나를 구하는 최적화 관점에서는 **MAP**가 답입니다.

5. NeuralSDF 논문과 비교하면 더 명확함

업로드한 NeuralSDF 충돌 검출 논문에서는 posterior가 아니라, 명확한 최적화 문제가 있습니다.

$$p^* = \arg \min_{p \in \Delta} f_{SDF}(p)$$

즉, 삼각형 안에서 SDF 값이 가장 작은 점 p^* 를 찾습니다. 논문에서는 이 NeuralSDF-triangle collision 문제를 제약 최적화로 만들고, KKT 조건을 이용해 amortized network가 contact point를 직접 예측하게 합니다.  0c0760_a300ee12f6054b399ed0e4b4...

이 경우의 “정답”은 분포가 아니라 하나의 점입니다.

$$p^*$$

반면 VAE나 Bayesian inference에서는 정답이 보통 하나의 점이 아니라 posterior 분포입니다.

$$p(z|x)$$

따라서 둘의 차이는 이렇게 볼 수 있습니다.

분야	구하려는 것	형태
Bayesian inference / VAE	posterior ($p(z x)$)	
MAP inference	z_{MAP}	하나의 점
NeuralSDF collision 논문	contact point p^*	하나의 점
amortized inference	$q_\phi(z x)$	
amortized optimization	$\hat{p} \approx p^*$	최적해 근사값

한 문장으로 정리

Posterior는 최적화의 정답 그 자체라기보다, 데이터를 본 뒤 숨은 변수에 대해 알고 싶은 “**목표 확률분포**”입니다.

다만 실제로는 이 posterior를 직접 계산하기 어렵기 때문에, 최적화를 통해 posterior를 근사하거나, posterior에서 가장 가능성 높은 MAP 값을 구합니다.

그럼 이 논문에서는 MAP 를 구하는거네

Thought for 1m 5s

네, 느낌은 **MAP**에 가깝습니다.

하지만 엄밀히 말하면 이 논문은 **MAP**를 구하는 것은 아니고, **deterministic constrained optimization**의 최적해 p^* 를 구합니다.

즉, 정리하면:

Posterior 전체를 구하는 문제는 아니고, 하나의 최적 **contact point**를 구하는 문제다.
그래서 “MAP처럼 하나의 최적 점을 찾는다”고 볼 수는 있지만, 논문 자체는 Bayesian MAP

문제가 아니다.

MAP와 이 논문의 차이

MAP는 보통 이런 문제입니다.

$$z_{MAP} = \arg \max_z p(z|x)$$

즉,

관측 x 가 주어졌을 때 posterior $p(z|x)$ 가 가장 큰 z 를 찾는 것

입니다.

반면 이 논문은 posterior가 없습니다. 논문에서 푸는 문제는 다음입니다.

$$p^* = \arg \min_{p \in \Delta} f_{SDF}(p)$$

또는 barycentric coordinate로 쓰면:

$$\min_{\alpha, \beta, \gamma} f_{SDF}(\alpha v_1 + \beta v_2 + \gamma v_3)$$

$$\text{s.t. } \alpha + \beta + \gamma = 1, \quad \alpha, \beta, \gamma \geq 0$$

즉,

삼각형 안에서 NeuralSDF 값이 가장 작은 점을 찾는 문제

입니다. 논문은 이 점을 NeuralSDF-triangle collision의 contact point로 사용합니다.

0c0760_a300ee12f6054b399ed0e4b4...

그래서 “MAP를 구한다”는 말은 언제 맞나?

비유적으로는 맞습니다.

둘 다 “전체 분포나 전체 공간을 다 들고 있는 것”이 아니라, 가장 좋은 하나의 점을 찾습니다.

구분

목표

Posterior inference

(p(z

MAP inference

posterior가 최대인 하나의 점 z_{MAP} 를 구함

이 논문

SDF가 최소인 하나의 contact point p^* 를 구함

그래서 이 논문은 posterior inference보다는 확실히 **MAP식 point estimation**과 더 비슷합니다.

하지만 엄밀히는 MAP가 아닙니다. 왜냐하면 MAP에는 반드시 확률분포가 있어야 합니다.

$$p(z|x)$$

이 논문에는 그런 posterior가 없고, 대신 SDF 목적함수

$$f_{SDF}(p)$$

가 있습니다.

더 정확한 표현

이 논문에서 구하는 것은 MAP가 아니라:

constrained optimization solution

즉,

$$p^* = \arg \min_{p \in \Delta} f_{SDF}(p)$$

입니다.

그리고 amortized neural network는 이 최적해를 직접 근사합니다.

$$\hat{p} \approx p^*$$

논문에서는 네트워크가 contact point p 자체를 직접 출력하지 않고, barycentric coordinate

$$[\alpha, \beta, \gamma]$$

를 출력합니다. 그다음

$$p = \alpha v_1 + \beta v_2 + \gamma v_3$$

로 contact point를 계산합니다. softmax를 사용해서 $\alpha + \beta + \gamma = 1, \alpha, \beta, \gamma \geq 0$ 조건을 만족하게 하므로, 예측점은 항상 삼각형 내부에 있습니다.

0c0760_a300ee12f6054b399ed0e4b4...

왜 MAP처럼 느껴지는가?

MAP는 보통 다음처럼 생각할 수 있습니다.

가장 그럴듯한 latent variable 하나 찾기

이 논문은 다음입니다.

가장 작은 SDF 값을 갖는 contact point 하나 찾기

둘 다 “하나의 최적 점”을 찾는 구조입니다.

그래서 개념적으로는:

VAE의 amortized inference가 posterior 근사분포 $q_\phi(z|x)$ 를 예측한다면,
이 논문의 amortized optimization은 최적 contact point $\hat{p}$ 를 예측한다.

라고 보면 됩니다.

확률적으로 억지로 해석하면?

만약 인위적으로 이런 분포를 정의한다면,

$$P(p|\Delta, SDF) \propto \exp(-f_{SDF}(p))$$

그러면

$$\arg \max_p P(p|\Delta, SDF) = \arg \min_p f_{SDF}(p)$$

가 됩니다.

이렇게 보면 이 논문의 해를 MAP처럼 해석할 수도 있습니다.

하지만 이건 우리가 새로 붙인 확률적 해석입니다. 논문 자체는 이런 posterior distribution을 정의하지 않습니다. 논문은 명확하게 **SDF 최소화 문제**와 **KKT optimality condition**으로 접근합니다.  0c0760_a300ee12f6054b399ed0e4b4...

결론

네, “posterior 전체를 구하는 게 아니라 하나의 최적점을 구한다”는 의미에서는 MAP와 비슷합니다.

하지만 더 정확히 말하면:

이 논문은 MAP inference가 아니라,
NeuralSDF-triangle constrained optimization의 최적해 p^* 를 구하고,
그 최적해를 amortized neural network가 한 번에 근사하도록 학습하는 것입니다.

즉,

$$\text{MAP : } \arg \max_z p(z|x)$$

$$\text{이 논문 : } \arg \min_{p \in \Delta} f_{SDF}(p)$$

입니다.

최적해를 구하고 근사를 해?

Thought for 1m 39s

네. 다만 표현을 조금 더 정확히 하면:

논문은 최적해를 매번 실제로 구한 뒤 근사하는 것이 아니라,
원래 구해야 할 최적해 p^* 를 신경망이 바로 근사하도록 학습합니다.

즉, “최적해를 구하고 → 그걸 근사한다”라기보다는,

최적해가 무엇인지 수학적으로 정의하고,
그 최적해가 만족해야 하는 조건을 이용해서,
네트워크가 최적해처럼 보이는 점을 바로 예측하게 만든다

가 더 정확합니다.

1. 원래 구해야 하는 최적해

이 논문에서 원래 풀고 싶은 문제는 이것입니다.

$$p^* = \arg \min_{p \in \Delta} f_{SDF}(p)$$

즉,

삼각형 위의 모든 점 중에서 NeuralSDF 값이 가장 작은 점 p^* 를 찾는다.

barycentric coordinate로 쓰면:

$$p = \alpha v_1 + \beta v_2 + \gamma v_3$$

$$\min_{\alpha, \beta, \gamma} f_{SDF}(\alpha v_1 + \beta v_2 + \gamma v_3)$$

$$\text{s.t. } \alpha + \beta + \gamma = 1, \quad \alpha, \beta, \gamma \geq 0$$

이 p^* 가 NeuralSDF 물체와 mesh 삼각형 사이의 contact point 후보입니다. 논문은 NeuralSDF-mesh 충돌을 여러 개의 NeuralSDF-triangle 문제로 나누고, 각 삼각형에서 이 최적점을 찾는 문제로 정의합니다. [0c0760_a300ee12f6054b399ed0e4b4...](#)

2. 기존 방식: 최적해를 매번 직접 구함

기존 Frank-Wolfe 방식은 실제로 매번 최적화를 합니다.

$$\text{triangle} \rightarrow \text{iterative optimization} \rightarrow p^*$$

즉, 각 삼각형마다 NeuralSDF를 여러 번 query하면서 SDF 값이 최소가 되는 점을 반복적으로 찾습니다.

이 방식은 정확할 수 있지만 느립니다. NeuralSDF는 한 번 query할 때도 신경망 forward pass가 필요하고, 반복 최적화는 이를 여러 번 호출하기 때문입니다. 논문에서도 이 점을 NeuralSDF 충돌 검출의 핵심 병목으로 설명합니다. [0c0760_a300ee12f6054b399ed0e4b4...](#)

3. 이 논문 방식: 최적해를 직접 풀지 않고 근사 예측

이 논문은 inference 때 최적화를 하지 않습니다.

대신 네트워크가 바로 예측합니다.

$$\text{triangle} + \text{shape feature} \rightarrow \text{amortized neural network} \rightarrow \hat{p}$$

여기서

$$\hat{p} \approx p^*$$

입니다.

즉, 네트워크 출력은 진짜 최적해 p^* 가 아니라, 그 최적해에 가까운 근사값 $\hat{p}$ 입니다.

네트워크는 p 자체를 직접 출력하지 않고 barycentric coordinate를 출력합니다.

$$[\alpha, \beta, \gamma] = \text{Network}(v_1, v_2, v_3, z_1, z_2, z_3, z_\Delta)$$

그다음

$$\hat{p} = \alpha v_1 + \beta v_2 + \gamma v_3$$

로 접촉점을 계산합니다. softmax를 사용하기 때문에 $\alpha + \beta + \gamma = 1, \alpha, \beta, \gamma \geq 0$ 가 자동으로 만족되어 $\hat{p}$ 는 항상 삼각형 내부에 있습니다.  0c0760_a300ee12f6054b399ed0e4b4...

4. 그럼 학습할 때 정답 최적해를 구하나?

핵심은 여기입니다.

이 논문은 기본적으로 정답 **contact point label**을 직접 사용해 **supervised learning**을 하는 방식이 아닙니다.

즉, 학습 때마다

$$p^* = \arg \min_{p \in \Delta} f_{SDF}(p)$$

를 정확히 구해서,

$$\hat{p} \approx p^*$$

가 되도록 L2 loss를 주는 방식이 아닙니다.

대신 KKT 조건을 사용합니다.

최적해라면 다음 조건을 만족해야 합니다.

$$(\nabla f_{SDF}(p))^T (p - v_{min}) = 0$$

그래서 네트워크가 예측한 $\hat{p}$ 에 대해 이 값이 0에 가까워지도록 학습합니다.

$$L_{op} = (\nabla f_{SDF}(\hat{p}))^T (\hat{p} - v_{min})$$

즉,

“정답 최적해 p^* 를 직접 알려주는 것”이 아니라,
“네가 예측한 점 $\hat{p}$ 가 최적해라면 만족해야 할 조건을 만족하라”

라고 학습시키는 것입니다.

논문은 이 loss가 추가 supervision 없이 KKT optimality condition을 만족하게 하므로 unsupervised learning을 가능하게 한다고 설명합니다.  0c0760_a300ee12f6054b399ed0e4b4...

5. 그런데 Frank-Wolfe를 아예 안 쓰는 건 아님

주의할 점이 하나 있습니다.

논문은 학습 loss로 Frank-Wolfe 정답을 직접 쓰지는 않지만, 데이터셋 구성과 평가에서는 Frank-Wolfe를 사용합니다.

예를 들어 training dataset을 만들 때 삼각형 조건을 확인하기 위해 minimum signed distance를 계산하고, 이때 Frank-Wolfe 100 iterations를 사용했다고 설명합니다. 또한 평가에서는 NME를 계산하기 위해 Frank-Wolfe 500 iterations 결과를 ground truth처럼 사용합니다.

0c0760_a300ee12f6054b399ed0e4b4...

하지만 핵심 학습 방식은 supervised label matching이 아니라 KKT 기반 loss입니다.

정리하면:

단계	최적해 직접 계산?	목적
문제 정의	수학적으로 p^* 정의	목표 설정
학습 loss	직접 p^* 라벨 사용 아님	KKT 조건으로 $\hat{p}$ 학습
데이터 구성	FW 일부 사용	학습 삼각형 필터링
평가	FW 사용	오차 비교용 기준값
실제 추론	FW 사용 안 함	네트워크가 $\hat{p}$ 바로 예측

6. 가장 정확한 문장

이 논문의 방법은 이렇게 말하는 게 가장 정확합니다.

최적해 p^* 를 반복 최적화로 매번 구하지 않고,
KKT 조건을 이용해 학습한 네트워크가 p^* 의 근사값 $\hat{p}$ 를 한 번의 forward pass로 예측한다.

즉,

$$p^* = \arg \min_{p \in \Delta} f_{SDF}(p)$$

를 직접 매번 풀지 않고,

$$\hat{p} = \text{Network}(\Delta, \text{shape feature})$$

로 근사합니다.

그리고 목표는

$$\hat{p} \approx p^*$$

입니다.

한 줄 결론

네, 최적해를 목표로 두고 그 최적해를 근사합니다.

하지만 실제 사용 시점에는 최적해를 먼저 구하지 않습니다. 네트워크가 최적해에 가까운 **contact point**를 바로 예측하는 것이 이 논문의 amortized neural network입니다.